AI AGENT · ENGINEERING IN PRODUCTION

AI Agent 工程化

从 Demo 到生产 — 需要的不只是大模型

FROM DEMO ~~TO P~~RODUCTION

的 Agent 项目止步于 Demo

真正进入生产，需要跨越四道工程化门槛

- 架构
- 上下文
- 评估
- 可观测

三道阻碍 Agent 落地的现实门槛

PERFORMANCE · COST · QUALITY — THREE BARRIERS BETWEEN DEMO AND PRODUCTION



PERFORMANCE

性能不稳定

多步推理累积误差

每一步 LLM 调用都有 5-10% 抖动，
叠加后总成功率断崖式下滑。

P95 延迟失控

链式调用让 P50 看似可控，
P95 / P99 翻 5-10 倍。

P95 / P50 RATIO **5-10×**



COST

成本不可预测

Token 漂移 5-50 倍

同一任务，不同上下文长度、
检索条数、循环深度，价格分布极宽。

长尾任务吞掉预算

5% 的疑难任务，
常常消耗 50% 以上的 token。

COST DRIFT RANGE **5-50×**



QUALITY

质量难闭环

失败原因模糊

是模型、提示词、工具，还是数据问题？
没有可观测层很难定位。

回归测试缺失

改一个 prompt，就要担心
十个老 case 是否回退。

DEBUG CYCLE COST **3-7 天**

Agent 的四层骨架

PERCEPTION · REASONING · ACTION · MEMORY

L1 · PERCEPTION 感知层	**输入解析** 用户意图分类、槽位抽取 语言识别、敏感词过滤	**多模态融合** 文本 · 图像 · 表格 · 音频 统一为可推理的结构化输入	**上下文窗口管理** 动态截断、关键信息前置 应对长 prompt 退化
L2 · REASONING 推理层	**Plan / ReAct** 先拆解，再推理 → 行动 观察结果再决定下一步	**Tree-of-Thought** 多路径展开 · 评估剪枝 适合搜索 · 规划 · 推理任务	**Reflection** 自检 · 自纠 · 自我评分 配合终止条件防止无限循环
L3 · ACTION 行动层	**工具调用** JSON schema 参数生成 超时 · 重试 · 鉴权治理	**函数执行** 沙盒 / 子进程 / WASM 代码生成必走隔离环境	**API 编排** 幂等 · 顺序 · 事务边界 幂等 key 防重复执行
L4 · MEMORY 记忆层	**短期上下文** 当前对话 / 当前任务窗口 滚动摘要防溢出	**长期向量库** 用户偏好 / 历史知识 / FAQ 语义 + 元数据双索引	**任务级缓存** 中间检索 / 工具调用结果 避免重复计算 · 降本利器

CHOOSING THE RIGHT PATTERN

Workflow · Agent · Multi-Agent — 选哪种？

三种主流模式按 " 路径确定性 " 递增 — 灵活性越高 , 工程化代价越大

MOST COMMON

PATTERN A
Workflow

DETERMINISTIC

- **路径固定**
  DAG 编排 ,LLM 只填空
- **可预测**
  每一步成本、延迟可量化
- **易调试**
  问题定位精确到节点

适合确定性任务

PATTERN B
Agent

EXPLORATORY

- **路径动态**
  运行时按情境自选下一步
- **LLM 决策**
  用模型判断 → 工具 / 继续 / 终止
- **工具调用**
  检索 · 计算 · 业务 API

适合半结构化探索

PATTERN C
Multi-Agent

COLLABORATIVE

- **多角色协作**
  Planner · Critic · Worker
- **任务分发**
  并发 / 串联 / 投票仲裁
- **上下文共享**
  共享黑板 / 消息总线

适合复杂长程任务

三种模式 · 路径确定性递减

让工具调用从 " 能跑 " 到 " 稳跑 "

TOOL ORCHESTRATION · A SIX-STEP DISCIPLINE

01

解析任务

拆解用户意图
明确目标和约束

输出 :
subtasks[]

PLAN

02

选择工具

schema 匹配
描述向量检索

输出 :
tool + args

SELECT

03

调用执行

超时控制
幂等 key

输出 :
raw_result

EXECUTE

04

验证返回

JSON schema
业务规则

输出 :
valid / fail

VALIDATE

05

重试回退

指数退避
降级路径

输出 :
retry / fallback

RECOVER

06

结果汇总

多轮聚合
引用与可解释化

输出 :
final answer

DELIVER

每步都可观测 · 每步都有回退

上下文，才是 Agent 真正的 " 权重 "

CONTEXT ENGINEERING · 1 CORE + 6 CAPABILITIES



上生产前，先把四张表盘装上

KPI DASHBOARD · WEEKLY ROLLUP

LIVE · W12

ACCURACY
任务成功率

92.4 %

▲ +3.2 pp
vs. 上周

12 周累计提升 21.4 pp · 接近内部 SLO 95% 阈值

LATENCY
P95 端到端延迟

4.8 s

▼ −18%
vs. 上周

引入并发工具调用 + 结果缓存后，P95 从 11.2s 收敛至 4.8s

COST
单次任务成本

¥0.42

▼ −22%
vs. 上周

关键来源：模型分级路由 + 检索结果缓存复用

RELIABILITY
30 天 SLO 达成率

99.7 %

▼ +0.4 pp
vs. 30 日前

熔断 + 降级链路 + 多模型 fallback 兜住了三次上游事故

持续优化的真实曲线 — 准确率 ↑成本 ↓

UPLINE TO PRODUCTION · 12-WEEK TREND



任务成功率 (左轴)

单次成本 (右轴)

▲准确率 71% → 92.4% · 成本 ¥1.20 → ¥0.42

12 周指标趋势 · 来源 : 内部 Agent 平台监控

这四类失败，你最先会遇到哪个

FAILURE MODES · FREQUENCY × DETECTION DIFFICULTY

	SHALLOW · 表面易识	DEEP · 隐蔽难定位
HIGH · 高频	**工具错误** — VALIDATE EARLY ● **JSON schema 不匹配** 字段缺失 / 类型错位 / enum 写飞 ● **参数幻觉** 不存在的参数 / 值越界 / 单位混用 ● **超时无回退**	**成本失控** — METER · CAP ● **Token 漂移** 长尾 prompt 把单次成本拉爆 ● **重复检索** 相同问句反复打向量库 · 无缓存 ● **链路过长 · 套娃调用**
LOW · 低频	**死循环** — HARD STOP ● **反思链路无终止** " 我再想想 " 无限循环 · 缺停机条件 ● **Plan 反复修改** 每步都重新拆解 · 上下文越塞越多 ● **工具调用环 · A 调 B 调 A**	**幻觉** — GROUND IT ● **编造工具** 调用不存在的工具名 / API endpoint ● **编造结果** 未调真实接口就给出 " 数据 " ● **假装成功 · " 已为您发送 "**

从原型到生产 — 12 周分四阶段

ROADMAP · PROTOTYPE → ENGINEERING → SCALE → PRODUCTION

W1 — W3

STAGE 01 · PROTOTYPE

原型 — 单一任务跑通

最小工具集 · prompt 初稿 · 5-10 个金标准 case 验证

W4 — W7

STAGE 02 · ENGINEERING

工程化 — 评估闭环

评估集 100+ · 自动回归 · 重试与降级机制全覆盖

W8 — W10

STAGE 03 · SCALE

规模化 — 性能与成本

结果缓存 · 限流熔断 · 多租户隔离 · 模型分级路由

W11 — W12

STAGE 04 · PRODUCTION

生产 — 灰度与 SLO

1% → 10% → 全量灰度 · SLO 监控 · 持续优化飞轮

SUCCESS CRITERIA

每阶段过线标准

01 **原型 → 工程化**
金标准 case 通过率 ≥ 80%

02 **工程化 → 规模化**
评估集 ≥ 100 · 自动回归绿灯

03 **规模化 → 生产**
P95 < 5s · 单次成本 < ¥0.5

04 **生产持续运营**
30 天 SLO ≥ 99.5% · 成本月度下降

⚡ **不达标不晋级 — 每个阶段必须有 " 通关 " 硬指标**

否则只是 " 进度 " 假象

YOUR TURN

下一个 Agent 从工程化开始

不是 " 加个 LLM", 是把 LLM 真正装进系统

开始 Agent 工程化

寻求合作

架构 · 上下文 · 评估 · 可观测 — 四件事一起做，才叫工程化