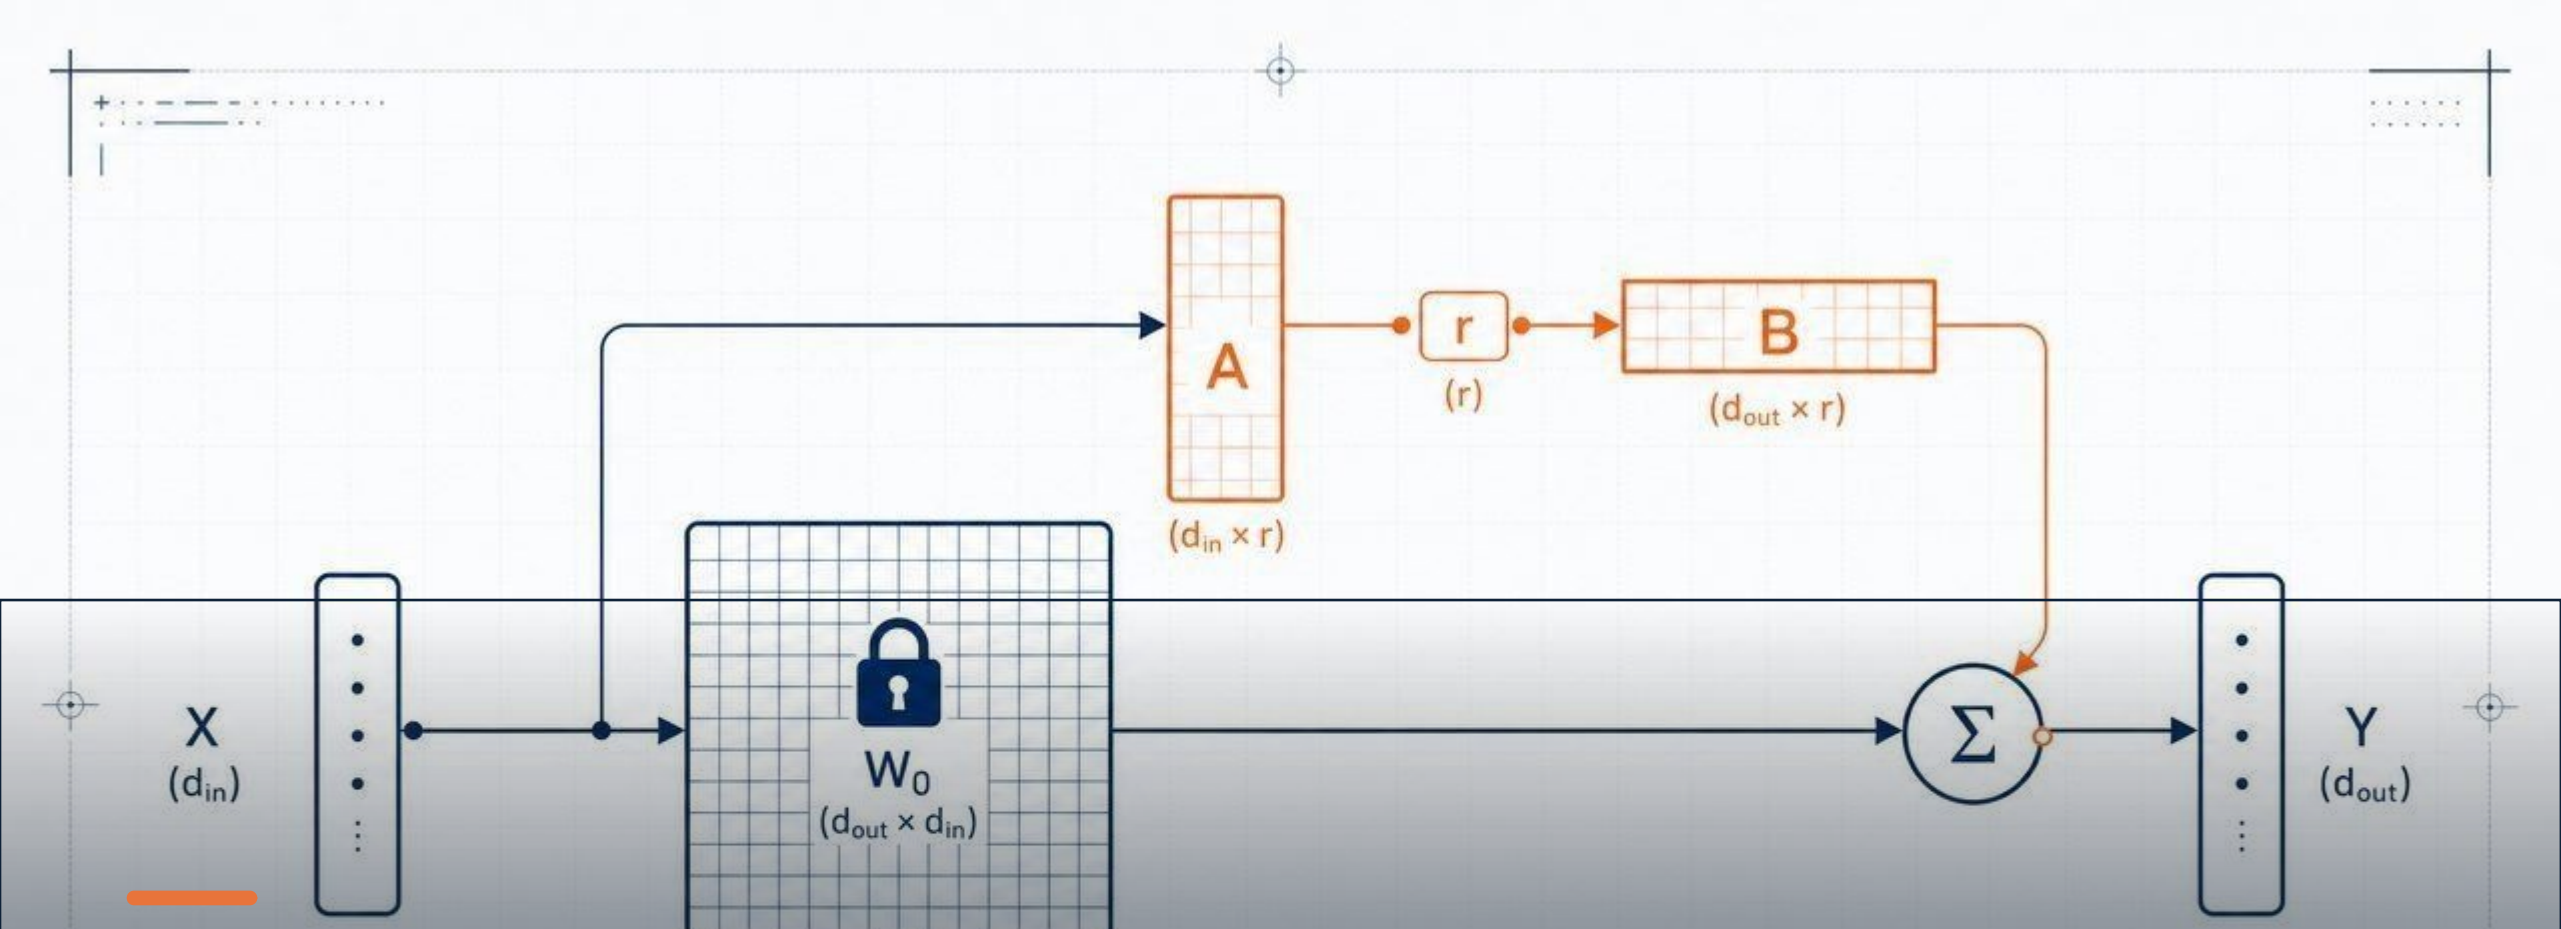


LoRA: 大模型的低秩适配

Low-Rank Adaptation of Large Language Models

Hu, Shen, Wallis, Allen-Zhu, Li, Wang, Wang, Chen · Microsoft · 2021

arXiv:2106.09685v2

LoRA

Low-Rank Adaptation

论文解读 · Paper Walkthrough

本次讲什么

WHAT WE'LL COVER · 从问题到方法到验证

01 **问题：微调为何越来越贵**

大模型时代，全量 fine-tuning 的存储与部署成本失控

02 **已有方法的局限**

Adapter 增延迟、 Prefix 占序列，且常达不到全量微调基线

03 **核心洞察：低秩假设**

权重更新 ΔW 具有低 " 内在秩 ", 极小的 r 就够用

04 **LoRA 方法与实现** · 核心

冻结 W_0, 注入低秩 BA; 只训 A 、 B, 部署可合并

05 **实验结果**

RoBERTa / DeBERTa / GPT-2 / GPT-3: 更少参数，持平或更优

06 **低秩理解与结论**

该适配哪些权重、秩要多大，以及对工程落地的意义

模型越大，全量微调越不可行

THE COST OF FULL FINE-TUNING

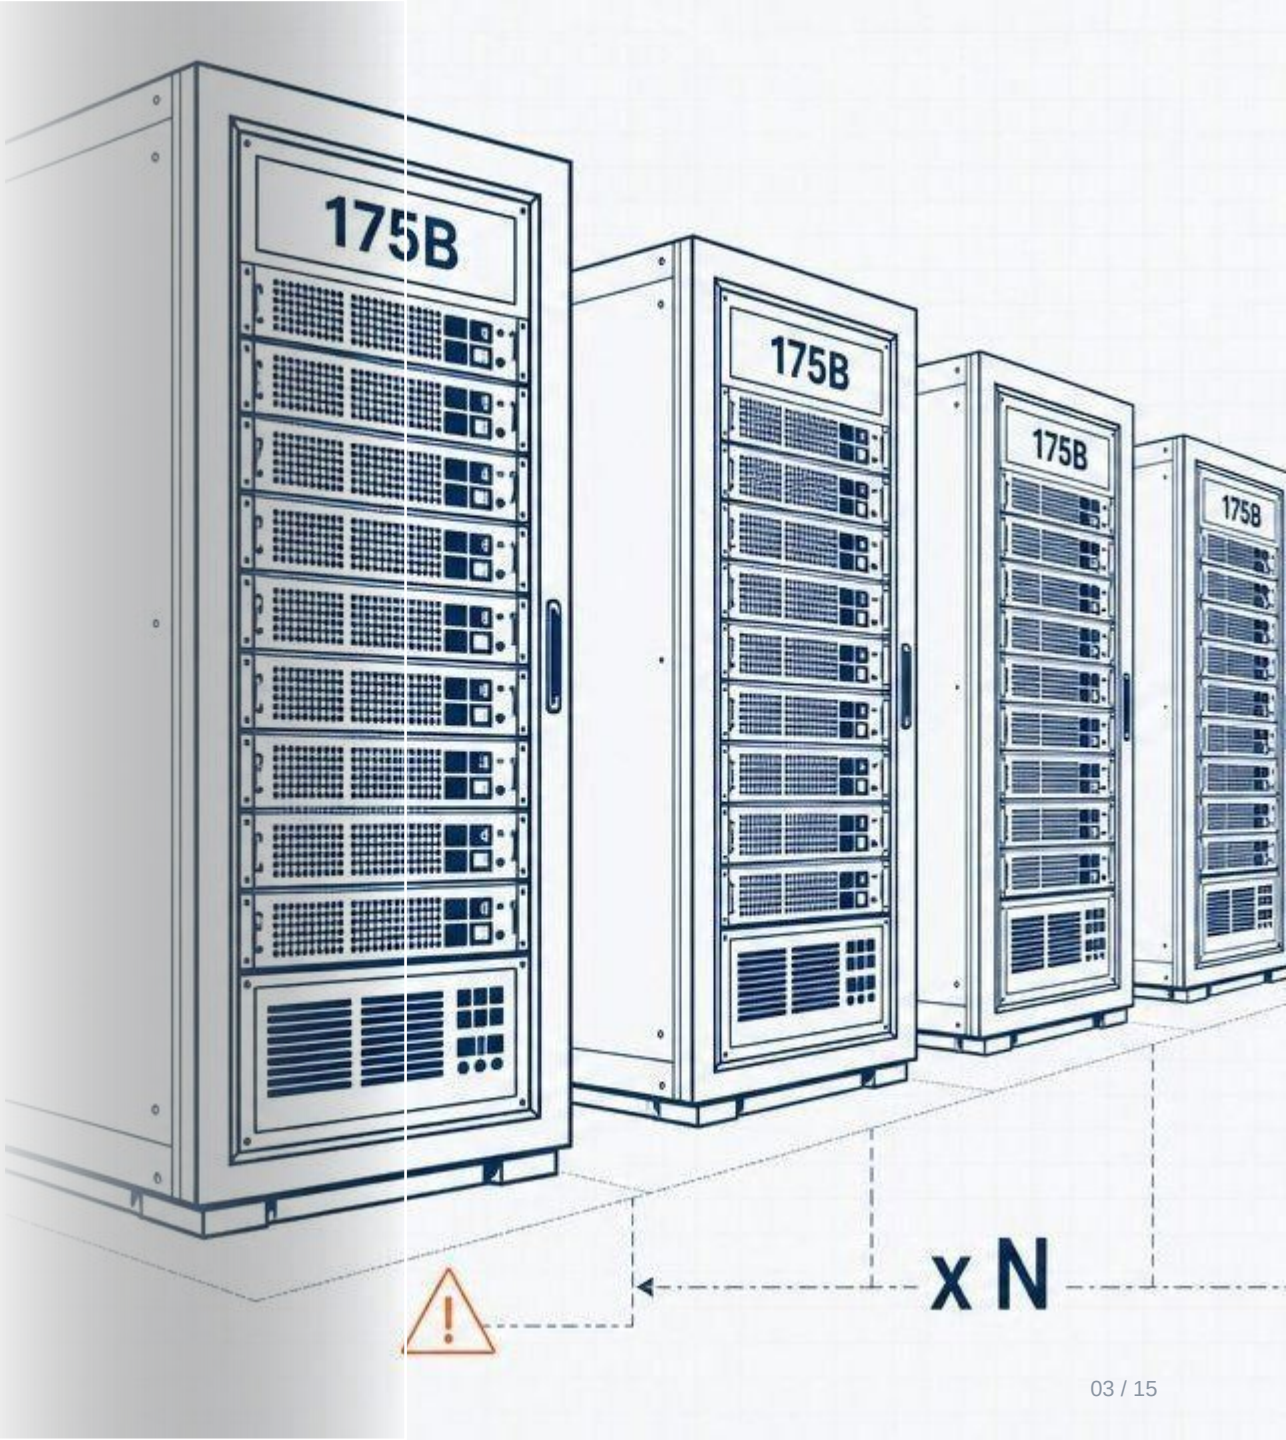
175B

每个下游任务都要存一份满参数副本

全量 fine-tuning 会更新 **全部参数**，新模型与原模型一样大

部署 N 个任务 → **N × 175B**，存储与切换成本极高

以 GPT-3 175B 为例，已从 " 不便 " 升级为**部署难题**



来源 :LoRA §1 Introduction · Hu et al. 2021

为什么现有高效适配方法不够好

LIMITS OF EXISTING EFFICIENT-ADAPTATION METHODS

01

Adapter 层 → 引入推理延迟

在自注意力 /MLP 后插入额外层 , 加深模型 ; 在线、短序列、小 batch 场景下延迟增加尤为明显 (后续 Table 1 量化) 。

02

Prefix / Prompt tuning → 占用输入长度

用可训练的前缀 token 适配任务 , 会挤占可用序列长度 ; 且前缀位置 / 数量敏感 , 优化较难。

03

普遍 →达不到全量微调基线

多数高效方法在质量上落后于 full fine-tuning, 迫使人在 " 效率 " 与 " 质量 " 之间二选一 —— 这正是 LoRA 想打破的权衡。

来源 :LoRA §1–3 · Hu et al. 2021

权重更新其实 " 低秩 "

THE LOW INTRINSIC-RANK HYPOTHESIS

① 已有证据

过参数化模型实际位于 **低内在维度** 上

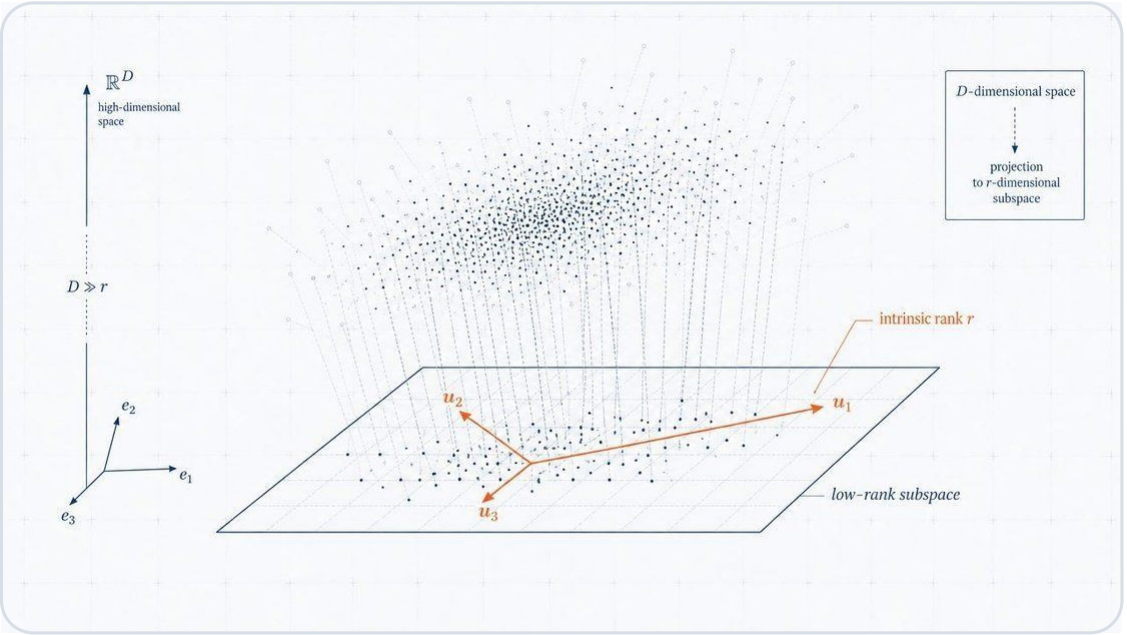
Li et al. 2018;Aghajanyan et al. 2020

② 本文假设

适配时的权重变化 ΔW 也具有低 **" 内在秩 "**

③ 推论

即使 d 高达 **12,288** ，极低的秩 ***r(1~2)*** 也够用

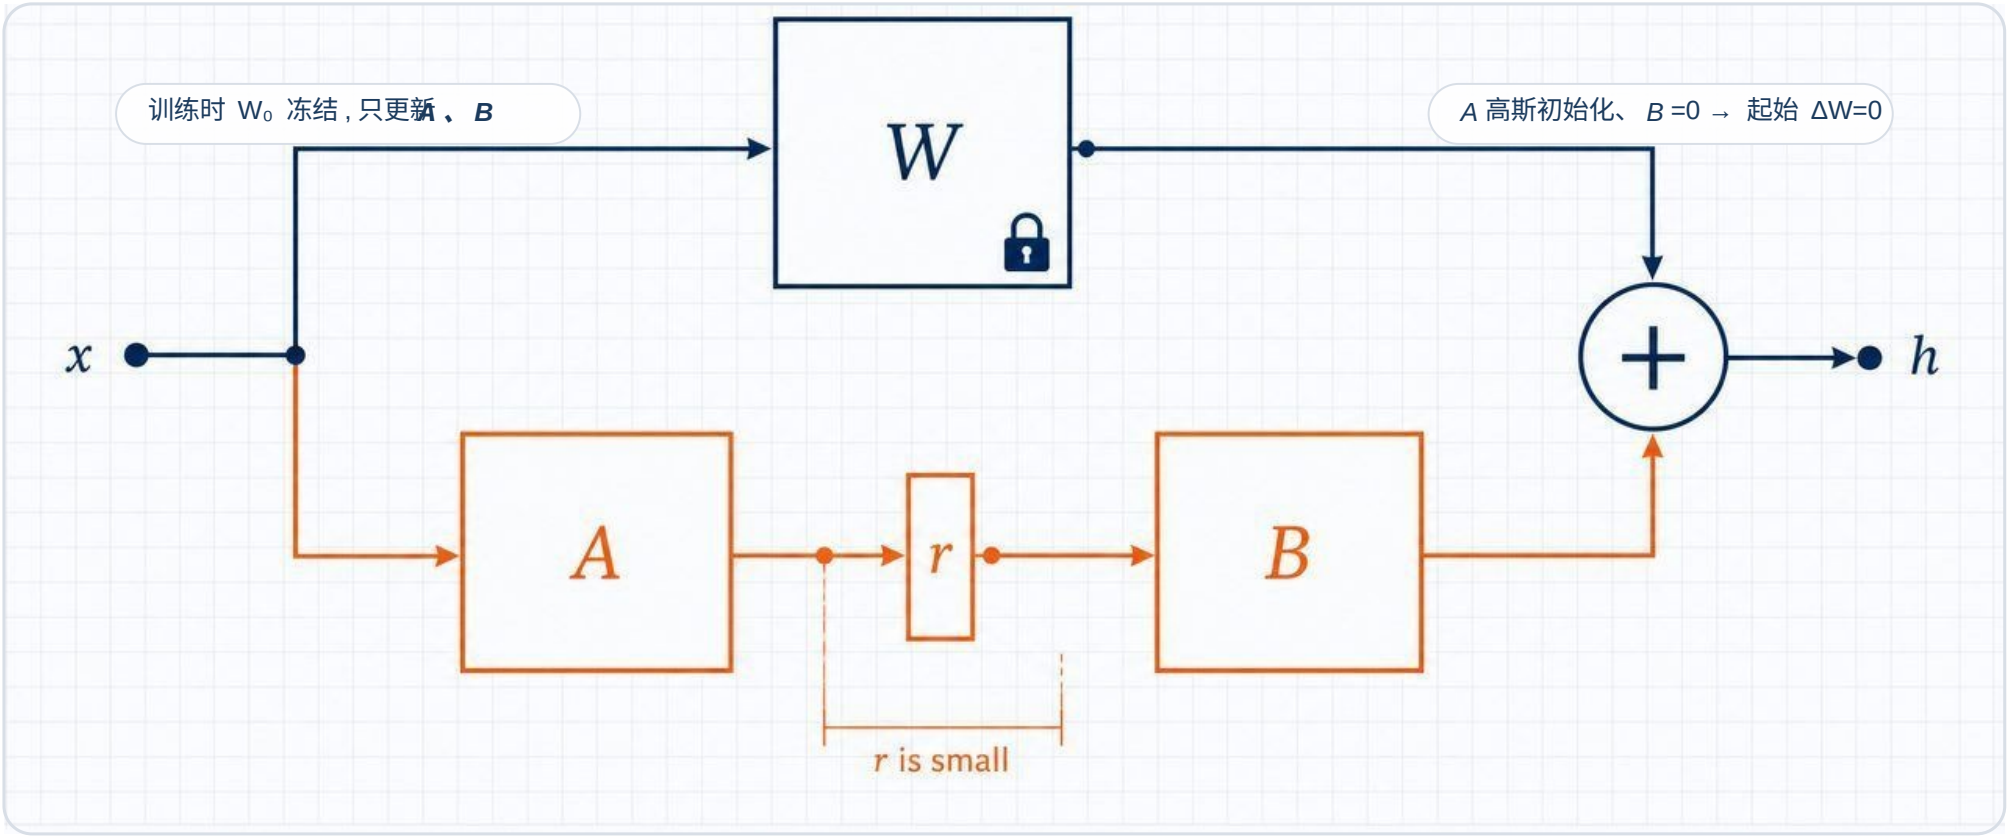


高维权重更新坍缩到低维子空间 (示意)

来源 :LoRA §1, §4.1 · Hu et al. 2021

冻结 W_0, 注入低秩 BA

THE LoRA REPARAMETRIZATION



低秩分解 $$W_0 + \Delta W = W_0 + BA, \quad B \in \mathbb{R}^{d\times r},\ A \in \mathbb{R}^{r\times k},\ r \ll \min(d,k)$$

前向传播 $$h = W_0 x + \Delta W x = W_0 x + BAx$$

两路输出逐坐标相加

来源 :LoRA §4.1, Eq.(3), Figure 1 · Hu et al. 2021

一个常数 α 、一次部署合并

INITIALIZATION, SCALING & DEPLOYMENT

缩放 : 一个常数 α

$$\Delta W x \cdot \frac{\alpha}{r}$$

ΔWx 按 **α/r** 缩放

α 设为首个尝试的 r,**不再单独调参**

变更 r 时减少超参重调的需要

用 Adam 时 , 调 α 约等于调学习率

部署 : 合并权重 , 零额外结构

显式计算并存储 **W = W₀ + BA**

推理时与原模型完全同构

→**不引入任何额外推理延迟**

换任务 : 快速热插拔

恢复 W_0 只需**减去 BA**

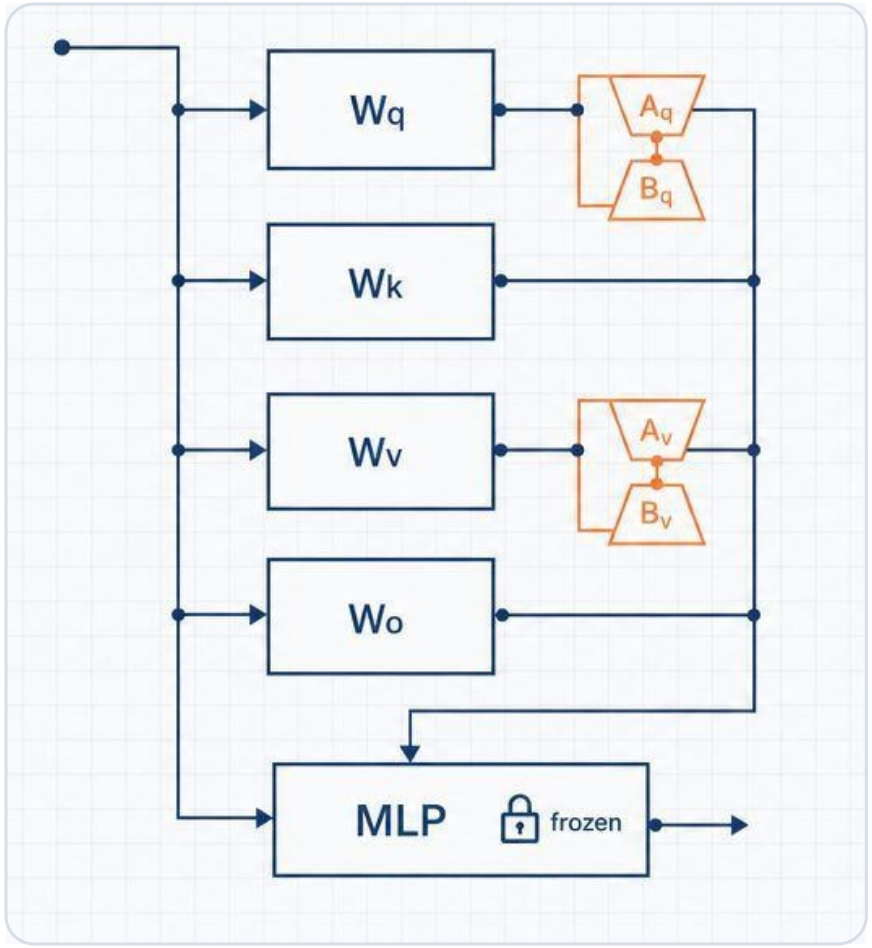
再加上另一任务的 **B′A′** 即可

内存开销极小 , 适合多任务在线切换

来源 :LoRA §4.1–4.2 · Hu et al. 2021

只适配注意力权重

APPLYING LoRA TO THE TRANSFORMER



自注意力的 Wq 、 Wv 各挂一条 LoRA 旁路 ,MLP 冻结

范围 : 四个投影 , 只动两个

自注意力含 **Wq / Wk / Wv / Wo**

实验中只适配 **Wq 、 Wv** ,冻结 MLP(为简洁与参数效率)

可训练参数量

$$|\Theta| = 2 \times \hat{L}_{\mathrm{LoRA}} \times d_{model} \times r$$

L_LoRA = 应用 LoRA 的权重矩阵数 ; 只随 r 线性增长

训练显存 VRAM(GPT-3 175B)

1.2TB → 350GB

约降至原来的 1/3

Checkpoint(r=4, 仅 Wq/Wv)

350GB → 35MB

约 10,000× 缩减

来源 :LoRA §4.2 · Hu et al. 2021

LoRA 的四个关键优势

FOUR KEY ADVANTAGES

01

可共享

ONE BASE · MANY MODULES

一个预训练底座 + 多个小 LoRA 模块；
换任务只需替换 **A**、**B** 显著降低存储。

02

高效训练

LOWER HARDWARE BARRIER

无需为冻结参数存梯度与优化器状态；
硬件门槛最高降低 **3×**。

03

零推理延迟

NO ADDED INFERENCE LATENCY

部署时合并 $W = W_0 + BA$；
与全量微调模型 **同构、不增延迟**。

04

正交可叠加

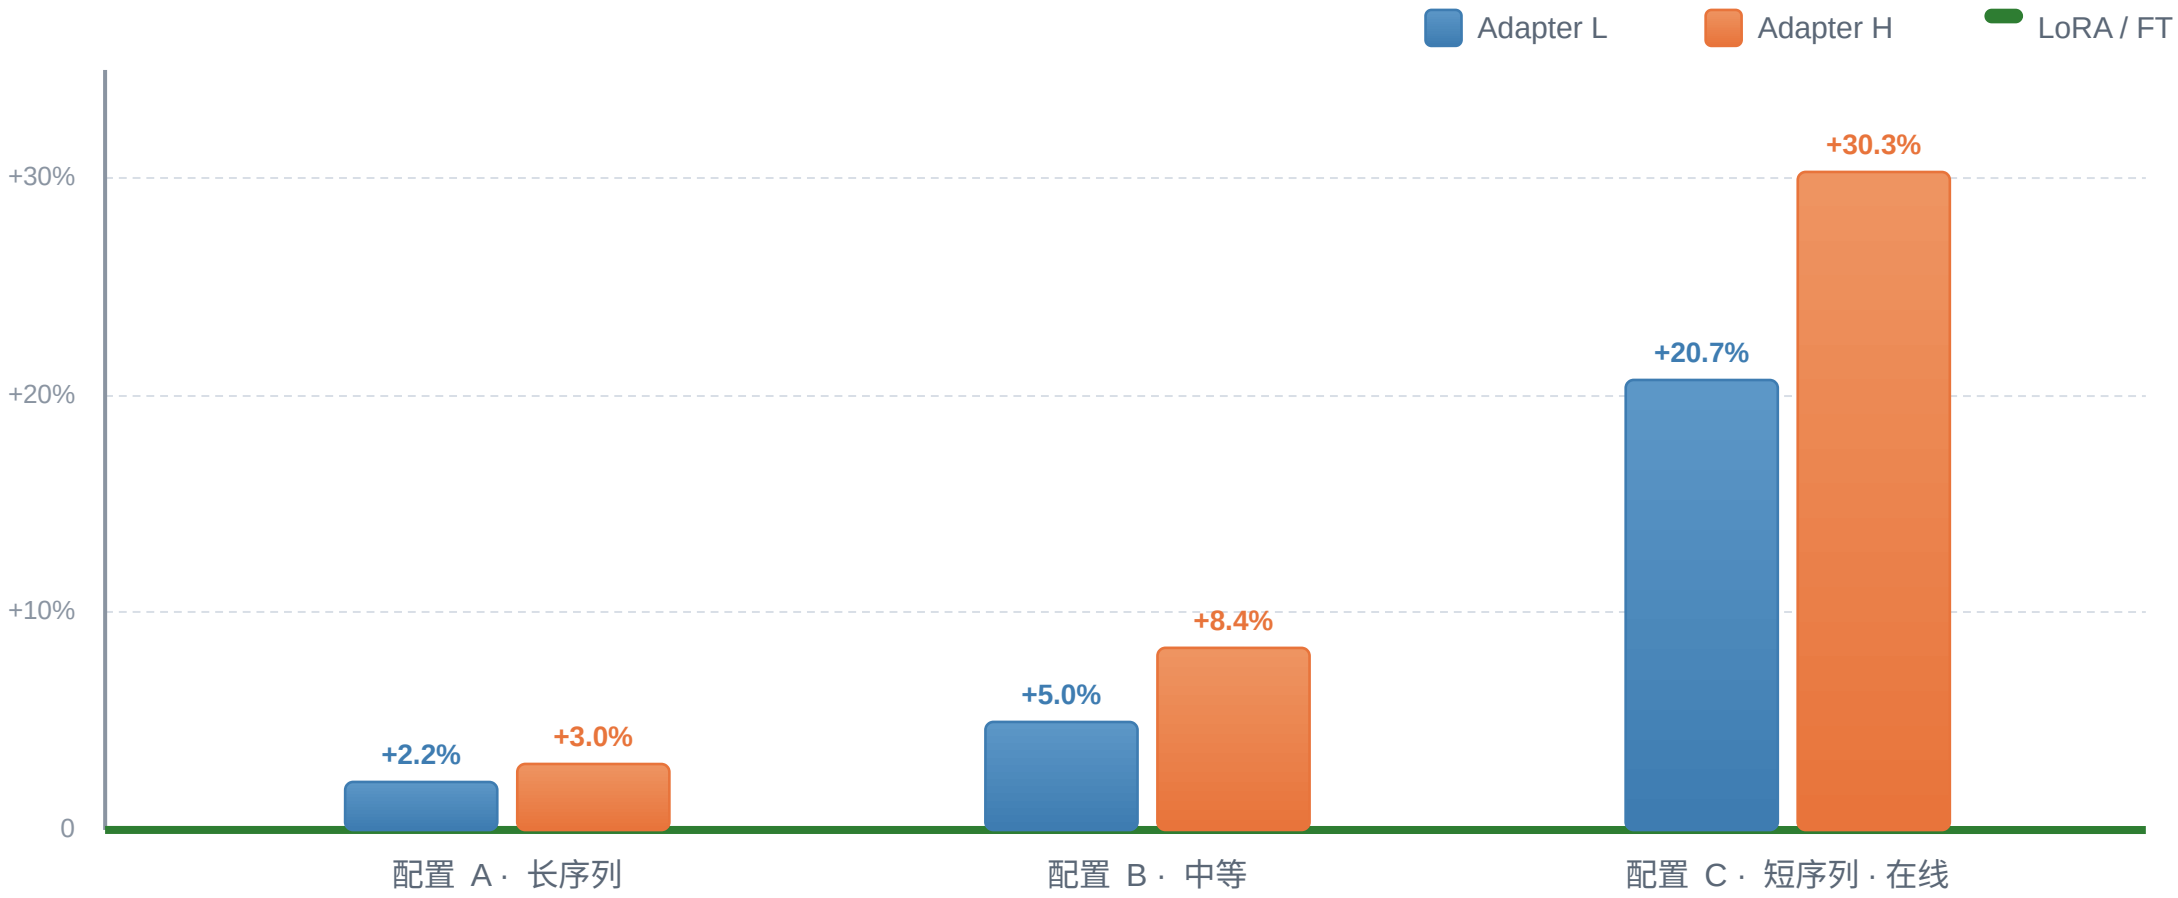
ORTHOGONAL · COMPOSABLE

与许多既有方法正交，
可与 **prefix-tuning** 等组合使用。

来源：LoRA §1, §4.1 · Hu et al. 2021

Adapter 增延迟 ,LoRA 不增

GPT-2 MEDIUM 单次前向延迟增幅 (100 次平均 , RTX8000)



LoRA / FT 基线 = 0% 额外延迟 (合并权重后)

序列越短、 batch 越小 ,Adapter 的延迟代价越突出

来源 :LoRA Table 1 · Hu et al. 2021

覆盖 NLU 到 NLG 的四类模型

EVALUATION SETUP · ROBERTA / DEBERTA / GPT-2 / GPT-3

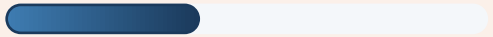
模型 MODEL	参数量	基准 BENCHMARK	任务	LoRA 可训练参数
RoBERTa base	125M	GLUE	NLU	**0.3M**
RoBERTa large	355M	GLUE	NLU	**0.8M**
DeBERTa XXL	1.5B	GLUE	NLU	**4.7M**
GPT-2 medium	354M	E2E NLG	NLG	**0.35M**
GPT-3	**175B**	WikiSQL · MNLI · SAMSum	NLU+NLG	**4.7–37.7M**

对比基线 :Fine-Tuning(FT) 、 BitFit 、 PreEmbed / PreLayer 、 Adapter H / L / P / D —— 尽可能复用前作报告数值

来源 :LoRA §5–5.1 · Hu et al. 2021

更少参数，持平或更优

GLUE BENCHMARK · OVERALL AVG SCORE(越高越好)

模型	方法	# 可训练参数	GLUE AVG	得分 (视觉)
RoBERTa base	FT	125M	86.4	
RoBERTa base	LoRA	0.3M	87.2	
RoBERTa large	FT	355M	88.9	
RoBERTa large	LoRA	0.8M	89.0	
DeBERTa XXL	FT	1500M	91.1	
DeBERTa XXL	LoRA	4.7M	91.3	

三类模型上，LoRA 用**1/300 ~ 1/400** 的可训练参数，GLUE 平均分**持平甚至略优于** 全量微调

来源：LoRA Table 2 · Hu et al. 2021

在 175B 尺度上仍然成立

GPT-3 175B · 关键指标 (对比全量微调)

可训练参数缩减

10,000×

checkpoint 350GB → **35MB**

训练显存 VRAM(原 1.2TB)

350GB

▼ 约降至 1/3

训练吞吐提升

+25%

无需为绝大多数参数计算梯度

任务准确率 : 持平 / 更优

≥ 全量微调

WikiSQL **74.0** · MNLI-m **91.7** · SAMSum **53.8**

三项均达到或超过 FT 基线

来源 :LoRA §4.2, Table 4, §6 · Hu et al. 2021

该适配谁？秩要多大？

UNDERSTANDING THE LOW-RANK UPDATES(GPT-3 175B, WikiSQL)

① 该适配哪些权重？(同等参数预算 18M)

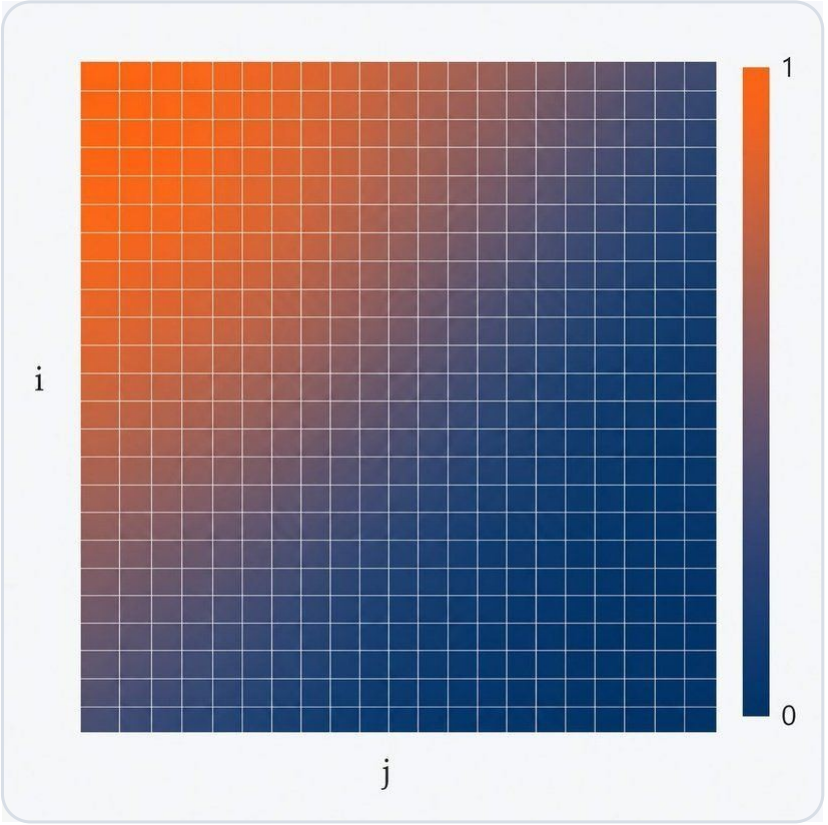
仅 Wq	70.4
Wq + Wv	**73.7 ★**
全部四个	73.7

适配 **{Wq, Wv}** 最佳 ——
分散到多类权重优于堆在单一类型

② 秩 r 要多大？(Wq+Wv 的验证准确率)

r = 1	r = 2	r = 4	r = 8	r = 64
73.4	73.3	73.7	73.8	73.5

r = 1 已足够 ; 增大 r 几乎无增益 → ΔW 的 " 内在秩 " 极低



子空间相似度 (Ar=8 vs Ar=64)

top 奇异方向高度重叠 , 其余迅速衰减

来源 :LoRA §7.1–7.2, Table 5/6, Figure 3 · Hu et al. 2021

结论与影响

CONCLUSION & IMPACT

01

方法本身

低秩适配 =**参数高效** + **零额外推理延迟** + 质量持平 / 更优

02

工程意义

一个预训练底座 **托管多任务** , 按需热插拔 LoRA 模块 , 部署成本骤降

03

行业影响

已开源 , 成为大模型微调的**事实标准之一** (PEFT 生态基石)

让人不必在 **效率** 与 **质量** 之间二选一

github.com/microsoft/LoRA

来源 :LoRA §8 Conclusion · Hu et al. 2021 · arXiv:2106.09685